

1. ESTRATEGIA Y VISIÓN DE NEGOCIO

En el sector Fintech, la gestión de la **Voz del Cliente (VoC)** trasciende el soporte técnico; es una pieza fundamental de la gestión de riesgos y cumplimiento. La estrategia implementada aborda la complejidad de operar en múltiples mercados bajo una premisa de "**Seguridad Semántica**". No buscamos simplemente clasificar tickets, sino identificar de forma proactiva incidentes que comprometan la continuidad operativa o la integridad regulatoria (Fraude, AML, Protección de Datos).

Para garantizar la fiabilidad del sistema, se ha diseñado una **Arquitectura de Triage Híbrida**. Mientras los LLM aportan una comprensión matizada del lenguaje y las emociones, un motor de reglas determinista supervisa cada salida. Este enfoque elimina la discrecionalidad técnica y asegura que las situaciones críticas sean escaladas a humanos con una **Prioridad P1/P2** garantizada, optimizando la asignación de recursos en las áreas de Brand, Soporte y Legal.

2. ARQUITECTURA DEL SISTEMA

El flujo está orquestado para ser robusto y auditable:

- **Ingesta & Normalización:** Localizado en `src/core/orchestrator.py`, el sistema detecta idioma y país automáticamente, asegurando que el contexto regional influya en el análisis sin intervención manual.
- **Validación de Entrada:** El módulo `src/core/guards.py` actúa como un firewall de costos, filtrando mensajes "ruido" o pruebas de sistema que no requieren procesamiento de IA.
- **Salida Estructurada:** Mediante el uso de Pydantic, forzamos que el motor de IA entregue datos listos para consumo programático, eliminando el riesgo de respuestas narrativas inconsistentes.
- **Motor de Scoring:** En `src/core/triage.py`, se calculan indicadores de urgencia que consideran el sentimiento negativo y factores de SLA acumulados.

3. STACK Y JUSTIFICACIÓN

- **FastAPI & Async:** Proporciona la infraestructura necesaria para escalar a miles de webhooks simultáneos con latencia mínima.
- **Multi-Provider Engine:** La implementación en `src/core/engine.py` garantiza resiliencia total; ante una caída de OpenAI o Gemini, el sistema alterna automáticamente al siguiente proveedor.
- **Configuración Dinámica:** Los umbrales de riesgo se gestionan desde `config/scoring.yaml`, permitiendo al equipo de negocio re-calibrar la sensibilidad del triage sin despliegues de código.
- **Trazabilidad SQLite:** Cada interacción queda registrada con su razonamiento, permitiendo auditorías posteriores ante reclamos regulatorios.

4. ESCALABILIDAD Y FUTURO

Escalabilidad de Infraestructura: El sistema está preparado para integrarse con CRMs (Zendesk) o gestores de incidentes. La arquitectura modular permite que nuevos canales de entrada (WhatsApp, Email, App) se conecten al mismo motor central sin fricción.

Modelos Mixtos y Eficiencia: Proyectamos un escenario realista de costos de ~\$40 USD para el volumen actual. El siguiente paso es el uso de modelos locales (Small Language Models) para consultas de baja prioridad, reservando la potencia de la nube para incidentes de alta complejidad.

Automatización Proactiva: Vemos este motor evolucionando hacia un agente de "Auto-Resolución", que no solo detecta el problema, sino que propone soluciones basadas en la política interna, reduciendo el trabajo operativo de los agentes de soporte hasta en un 70%.