

VoC Intelligence: Estrategia de Triage y Mitigación de Riesgos

github.com/vmuster/global66-businesscase | vicentemuster@gmail.com

I. El Problema: El costo del silencio y el ruido

Hoy, el equipo humano solo puede procesar el 10% de los mensajes, dejando una brecha de 48 horas donde riesgos de fraude, cumplimiento (AML) y fallos críticos de producto quedan ocultos en el ruido. El objetivo estratégico es cerrar esa brecha al 0%, procesando el 100% del volumen entrante en tiempo real. No buscamos reemplazar al analista, sino priorizar su talento donde el impacto en el negocio es máximo.

II. Arquitectura de Solución y Ciclo de Mejora (HITL)

Se implementó una arquitectura orientada a eventos con un enfoque de Human-in-the-Loop (HITL) para garantizar la precisión:

- **Motor de Inferencia Híbrido:** El diseño es agnóstico al proveedor, permitiendo usar modelos cerrados (Gemini/OpenAI) para análisis complejos o modelos Open Source (Llama 3/Mistral) para garantizar la soberanía de datos y reducir costos en tareas de clasificación masiva.
- **Contrato de Datos Estricto:** Mediante Pydantic, forzamos que la IA entregue esquemas JSON válidos, eliminando el riesgo de alucinaciones en los reportes de auditoría.

Feedback loop (aprendizaje en paralelo con el humano): Las escalaciones al equipo humano se retroalimentan al sistema. Esta revisión en paralelo permite crear un *ground truth* para el re-entrenamiento (fine-tuning) del motor de etiquetado, reduciendo falsos positivos con el tiempo.

III. Gobernanza, Legalidad y Adaptabilidad Local

Dada la naturaleza multinacional de Global66, el sistema resuelve el cumplimiento legal mediante Policy-as-Code:

Políticas por región (YAML) — sin tocar el motor: La lógica de negocio no está “hardcodeada”, sino en archivos de configuración. Eso permite cargar reglas específicas para cumplir con la normativa local de cada país (por ejemplo, protección de datos o plazos de respuesta legales) **sin alterar el código del motor de inferencia** — solo la capa de política versionada.

Privacidad: La capacidad de usar modelos open-weight en servidores propios asegura que los datos sensibles del cliente nunca abandonen la infraestructura controlada si la normativa así lo exige.

IV. Business Case: Escalabilidad y Eficiencia

Costo por mensaje: \$0.0004 USD.

Proyección a 100,000 casos: El gasto operativo proyectado es de \$41 USD mensuales.

Escala: El desacoplamiento entre la ingesta (FastAPI) y el procesamiento asegura que picos de demanda no degraden la latencia del servicio, utilizando colas asíncronas para una entrega fluida.